有向图上的非马尔科夫随机游走：高阶转移模型、路径概率推断与图神经网络优化

研究课题形式化说明

结合知识图谱多跳推理 · AI Optimization

摘要 本文研究有向图上的**非马尔科夫随机游走**问题。与经典马尔科夫游走（下一步只看当前位置）不同，我们的模型允许下一条边的选择概率依赖于最近走过的 k 条边的完整历史。这一设定更贴近现实：人开车转弯会受来路影响，知识图谱推理的下一跳依赖整条推理链。我们形式化定义 k 阶边转移张量，提出三个核心研究问题（阶数提升、路径概率计算、最大概率路径搜索），并设计基于**图神经网络（GNN）**的统一求解框架，直接对应知识图谱中的多跳推理任务。

关键词： 非马尔科夫游走 · 高阶马尔科夫链 · 有向图 · 线图 · 边转移张量 · 图神经网络 · 知识图谱 · 多跳推理 · 组合优化

Contents

1 直觉与动机：为什么要研究非马尔科夫游走？ 2
1.1 一个生活中的例子 2
1.2 为什么这件事很重要？ 2

2 图与游走的正式定义 3
2.1 基本符号 3
2.2 马尔科夫游走（经典模型） 3
2.3 非马尔科夫游走（本研究模型） 3

3 三个核心研究问题 4

4 复杂度分析：为什么不能暴力求解？ 5

5 图神经网络求解框架 6
5.1 核心思路：把边变成节点——线图构造 6
5.2 整体框架 6
5.3 训练目标 7

6 与知识图谱多跳推理的对应关系 7
6.1 对应关系 7
6.2 典型的多跳问题 8

7 研究问题汇总 8

8 总结 8

1 直觉与动机：为什么要研究非马尔科夫游走？

1.1 一个生活中的例子 想象你在一个城市的路口网络中开车。到达某个十字路口时，你选择左转还是右转，**不仅取决于你现在在哪个路口，还取决于你刚才是从哪条路开来的**。

- 如果你沿着高速路匝道来，你更可能继续直行；
- 如果你从小区出来，你更可能右转上主干道。

这就是**非马尔科夫性**的本质：历史路径影响当前决策，而经典的马尔科夫模型会忽略这一点。

如图 1所示，两种模型在同一路口给出截然不同的转向概率。

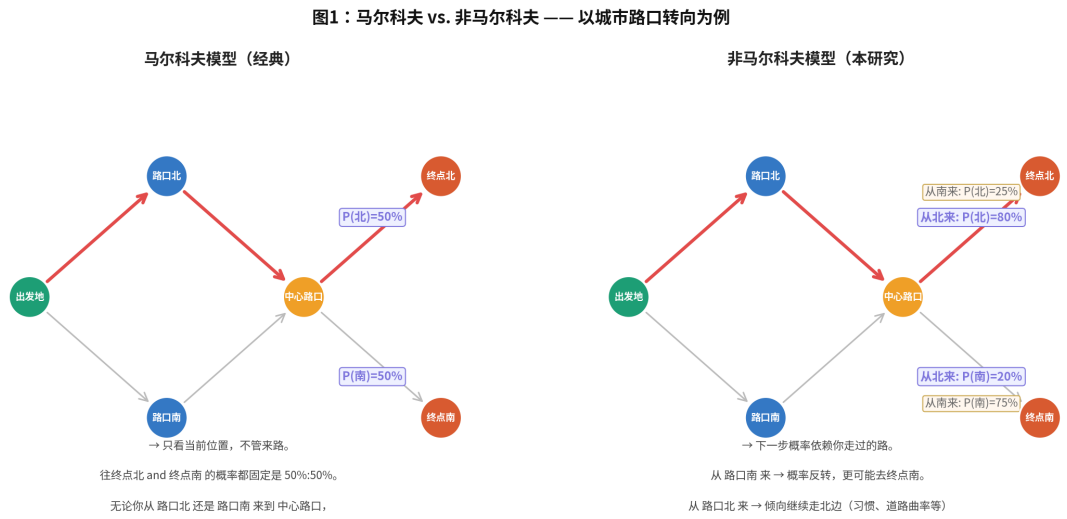

Figure 1: 马尔科夫模型 vs. 非马尔科夫模型的对比——以城市路口为例。左图：不管来路如何，到达中心路口后的转向概率固定（50%:50%）。右图：从北边来的车更倾向继续走北边（80%），体现来路对决策的影响。

1.2 为什么这件事很重要？ 目前绝大多数图上的随机游走模型，包括 PageRank、Node2Vec、随机游走嵌入等，都**假设马尔科夫性**——即游走的下一步只与当前顶点有关。然而在很多现实场景中，这一假设是错误的：

- **交通网络**：车辆的惯性、道路曲率使转向概率依赖来路；
- **知识图谱推理**：回答”诺兰在哪个大洲拍的片？”需要沿关系链推理，每一跳的关系选择依赖整条推理前缀；
- **推荐系统**：用户的下一次点击不只取决于当前页面，还取决于近期的浏览序列；
- **社交网络传播**：信息在人群中的扩散路径有记忆效应。

本研究的核心价值

本研究**首次系统地**用图神经网络框架处理有向图上的非马尔科夫游走，提供了一种可学习、可扩展的高阶转移模型，兼顾理论完整性（张量形式化）与实际可行性（GNN 近似）。

2 图与游走的正式定义

2.1 基本符号 设 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 是一个有限**有向图**，其中 $\mathcal{V}$ 是顶点集（$|\mathcal{V}| = N$），$\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$ 是有向边集（$|\mathcal{E}| = M$）。对于边 $e = (u, v)$，记 $\mathrm{src}(e) = u$（起点），$\mathrm{tgt}(e) = v$（终点）。

边 e 的后继集定义为从 e 的终点出发的所有边：

$$\mathcal{S}(e) = \{e' \in \mathcal{E} \mid \mathrm{src}(e') = \mathrm{tgt}(e)\}, \qquad |\mathcal{S}(e)| = d_e.$$

$d = \max_e d_e$ 称为最大出度。**长度为 ℓ 的游走**是满足 $e_{t+1} \in \mathcal{S}(e_t)$ 的边序列 $\boldsymbol{w} = (e_1, e_2, \ldots, e_\ell)$。

2.2 马尔科夫游走（经典模型） 在经典马尔科夫框架下，转移概率**只依赖当前顶点**：

$$\Pr(e_{t+1} \mid e_1, \ldots, e_t) = \Pr(e_{t+1} \mid \mathrm{tgt}(e_t)) =: P^{(0)}(\mathrm{tgt}(e_t),\ e_{t+1}).$$

这构成 $N \times N$ 的**顶点转移矩阵** $P^{(0)}$。其局限在于：到达同一个顶点，无论是从左边来还是右边来，选择下一步的分布完全相同。

2.3 非马尔科夫游走（本研究模型）

定义 1：k 阶边转移张量

k **阶边转移模型**将转移概率定义为最近 k 条边历史的函数：

$$\Pr(e_{t+1} \mid e_t, e_{t-1}, \ldots, e_{t-k+1}) =: T^{(k)}(e_{t-k+1}, \ldots, e_{t-1}, e_t,\ e_{t+1}),$$

满足 $\displaystyle\sum_{e' \in \mathcal{S}(e_t)} T^{(k)}(\cdot) = 1$（概率归一化）。

直觉解释： 把 k 理解为”记忆深度”——你最近走过的 k 条边构成系统的”当前状态”。

- $k = 0$（马尔科夫）：只知道自己在哪个顶点，不记来路；
- $k = 1$（一步记忆）：知道上一条边，状态空间是所有边 $\mathcal{E}$，参数量 $M \times d$；
- $k = 2$（两步记忆）：记住最近两条边，参数量 $M \times d^2$；
- 一般 k：状态空间 $M \cdot d^{k-1}$，参数量 $M \times d^k$。

如图 2所示，随着 k 增大，状态空间指数爆炸。

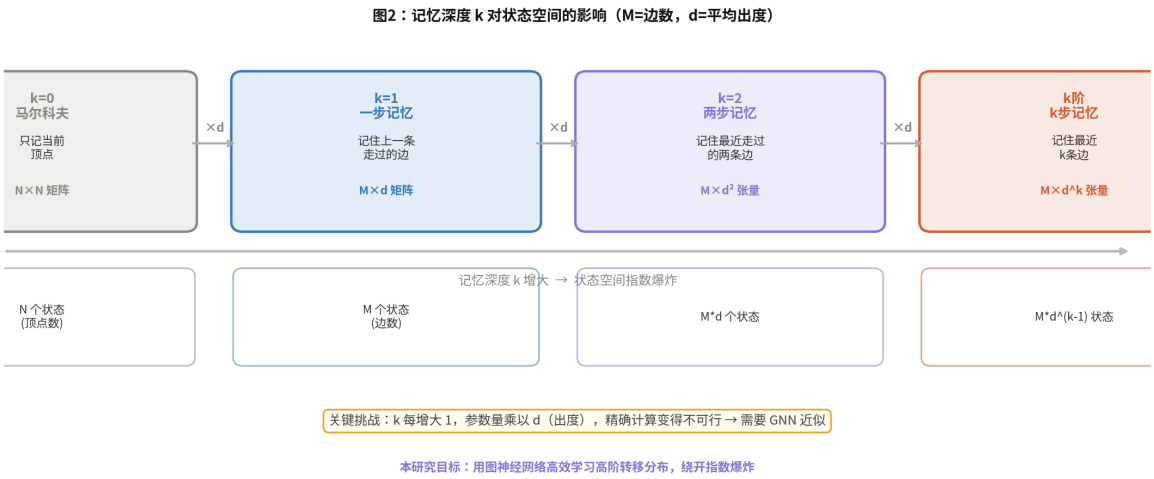

Figure 2: 记忆深度 k 与状态空间大小的关系。每增加一阶，参数量乘以出度 d，精确方法很快变得不可行，这正是需要 GNN 学习近似的根本动机。

3 三个核心研究问题

本研究聚焦于三个由浅入深的核心问题，如图 3所示。

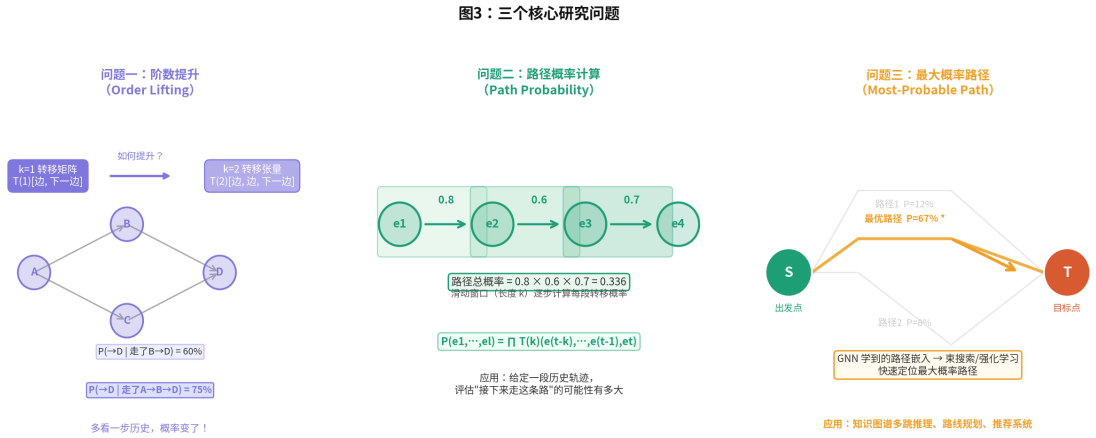

Figure 3: 三个核心研究问题的直觉图示。从左到右依次是：阶数提升（了解" 多看一步历史有什么用"），路径概率计算（" 这条路被走到的可能性有多大"），最大概率路径（" 从 S 到 T 最可能走哪条路"）。

研究问题 1：阶数提升（Order Lifting）

问： 已知 k 阶转移张量 $T^{(k)}$，如何推导或学习 $T^{(k+1)}$？多看一步历史，概率如何变化？

形式化： 两阶之间满足边缘化约束——k 阶模型是 $(k+1)$ 阶模型对最远那步历史求和的结果：

$$T^{(k)}(e_{-k+1},\dots,e_0,\,e_1) = \sum_{\substack{e_{-k}:\\ e_{-k+1}\in\mathcal{S}(e_{-k})}} T^{(k+1)}(e_{-k},\dots,e_0,\,e_1)\cdot \Pr(e_{-k}).$$

挑战： 每增加一阶，参数量乘以 d，直接存储不可行（$M=10^6, d=50, k=3$：参数量达 $10^6\times 50^3 = 1.25\times 10^{11}$）。

研究问题 2：路径概率计算（Path Probability）

问： 给定一段已走过的前缀路径 $(e_1,\dots,e_t)$，走接下来一段特定路径 $(e_{t+1},\dots,e_{t+\ell})$ 的**总概率**是多少？

形式化：

$$\Pr(e_{t+1},\dots,e_{t+\ell}\mid e_1,\dots,e_t) = \prod_{s=t}^{t+\ell-1} T^{(k)}(e_{s-k+1},\dots,e_s,\,e_{s+1}).$$

直觉： 用一个”滑动窗口”沿路径逐段相乘，每段的转移概率由最近 k 条边决定。
挑战： (1) 窗口边界处历史不完整需特殊处理；(2) 路径很长时连乘会数值下溢，需转为对数概率求和；(3) 枚举所有可能路径的复杂度是指数级的。

研究问题 3：最大概率路径（Most-Probable Path）

问： 给定相距较远的两点 $s,t\in\mathcal{V}$，从 s 到 t 所有可能路径中，**哪条被走到的概率最大**？

形式化：

$$\boldsymbol{w}^* = \underset{\substack{\boldsymbol{w}=(e_1,\dots,e_L)\\ \mathrm{src}(e_1)=s,\ \mathrm{tgt}(e_L)=t}}{\arg\max} \sum_{\ell=1}^{L} \log T^{(k)}(e_{\ell-k},\dots,e_{\ell-1},\,e_\ell).$$

直觉： 在一棵巨大的决策树里找到从根（s）到目标叶子（t）的最优路径。
挑战： 精确动态规划的状态空间为 $\mathcal{E}^k$，复杂度 $O(M^k\cdot L)$，对大图完全不可行。需要 GNN 学习的路径嵌入来做近似推断。

4 复杂度分析：为什么不能暴力求解？

下表总结了不同阶数下的状态空间与计算复杂度：

阶数 k	游走状态（”记住什么”）	状态数	张量大小	DP 复杂度
0（马尔科夫）	当前顶点 v	N	$N\times N$	$O(N^2L)$
1	上一条边 e	M	$M\times d$	$O(MdL)$
2	最近两条边 (e_{-1},e)	$M\cdot d$	$M\times d^2$	$O(Md^2L)$
k	最近 k 条边	$M\cdot d^{k-1}$	$M\times d^k$	$O(Md^kL)$

核心矛盾

参数量和计算量随 k **指数增长**，而现实数据（如知识图谱）中 M 可达百万、d 可达数十——哪怕 $k=3$ 也意味着数百亿参数。**这是该方向此前鲜有人系统研究的根本原因，也正是 GNN 近似的用武之地。**

5 图神经网络求解框架

5.1 核心思路：把边变成节点——线图构造 解决非马尔科夫游走的关键洞见是：**把原图的每条"边"变成新图的"节点"。**

这个新图叫做**线图**（Line Graph）$\mathcal{L}(\mathcal{G})$：

- 线图的每个节点 = 原图的一条边 $e \in \mathcal{E}$；
- 线图中从 e 到 e' 有连边，当且仅当 $e' \in \mathcal{S}(e)$（即原图中 e 的终点 = e' 的起点）。

为什么这样做有效？ 在线图上做消息传递，每个"边节点"聚合来自"上一条边节点"的信息，天然地编码了"走完某条边之后选下一条边"这一非马尔科夫依赖关系。k 层消息传递对应 k 步历史。

5.2 整体框架 如图 4所示，整个框架包含四个阶段：

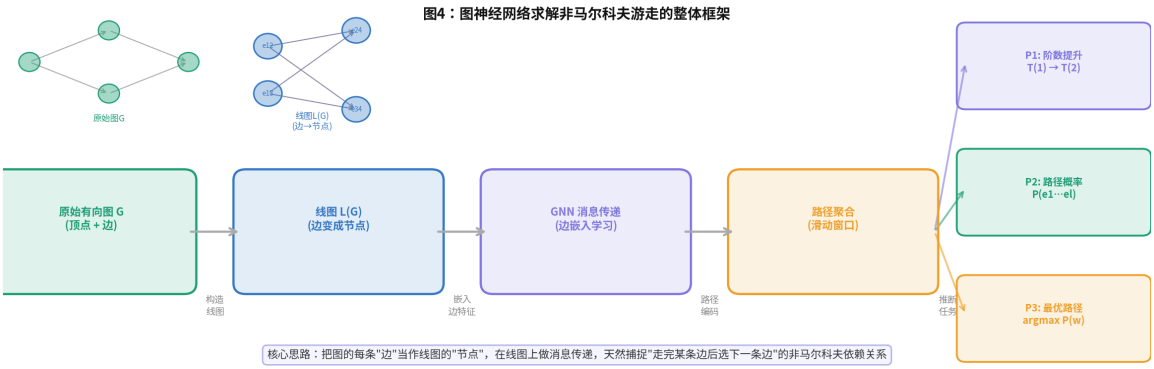

Figure 4: GNN 求解非马尔科夫游走的整体流程。原始有向图 $\mathcal{G}$ 被转换为线图 $\mathcal{L}(\mathcal{G})$，在线图上进行多层 GNN 消息传递以学习边嵌入，再通过路径聚合模块输出三个研究问题的答案。

第一步：构造线图 $\mathcal{L}(\mathcal{G})$。 将原图的 M 条边变成 M 个节点，相邻边之间连弧。线图节点的初始特征可以包括：边的方向、端点的度数、边的类型（在知识图谱中即关系类型）等。

第二步：GNN 消息传递（边嵌入学习）。 在线图上进行 k 层消息传递：

$$h_e^{(l+1)} = \mathrm{AGGREGATE}\Big(h_e^{(l)},\ \{h_{e'}^{(l)} : e' \in \mathcal{S}^{-1}(e)\}\Big),$$

其中 $\mathcal{S}^{-1}(e)$ 是 e 的前驱边集合。第 l 层的隐藏向量 $h_e^{(l)}$ 隐式地编码了长度为 l 的历史信息。

第三步：路径聚合。 对于给定路径 $(e_1, \ldots, e_\ell)$，用滑动窗口对边嵌入序列做聚合（如 LSTM、注意力机制），得到路径级表示。

第四步：任务特定输出头。

- **问题一（阶数提升）**：用 MLP 预测 $\hat{T}^{(k)}(e, e')$，加入边缘化一致性正则项；
- **问题二（路径概率）**：路径嵌入通过评分函数给出对数概率；
- **问题三（最优路径）**：在 GNN 代理上做束搜索（Beam Search）或强化学习（Policy Gradient）。

5.3 训练目标

设 $\mathcal{D} = \{\boldsymbol{w}^{(i)}\}$ 为观测到的游走数据集。最小化负对数似然：

$$\mathcal{L}_{\mathrm{NLL}}(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{\boldsymbol{w} \in \mathcal{D}} \sum_{t=k}^{|\boldsymbol{w}|-1} \log \hat{T}_\theta^{(k)}\big(e_{t-k+1}, \ldots, e_t,\ e_{t+1}\big).$$

加入**阶数一致性正则项**，强制高阶张量边缘化后等于低阶张量：

$$\mathcal{L}_{\mathrm{cons}}(\theta) = \sum_{e,e'} \Big\| \hat{T}^{(1)}(e, e') - \sum_{e'' \in \mathcal{S}^{-1}(e)} \hat{T}^{(2)}(e'', e, e') \cdot \hat{\mu}(e'') \Big\|_2^2,$$

其中 $\hat{\mu}$ 是一阶链的平稳分布。

6 与知识图谱多跳推理的对应关系

如图 5所示，知识图谱（KG）是本研究最直接的应用场景之一。

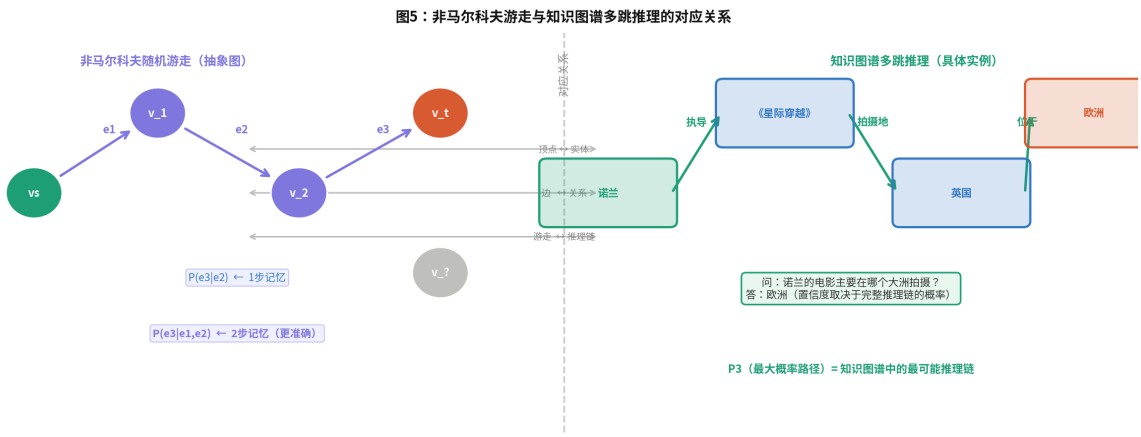

Figure 5: 非马尔科夫游走与知识图谱多跳推理的对应关系。图的顶点对应实体，边对应关系，游走对应推理链。问题三（最大概率路径）直接给出知识图谱问答中最可信的推理链。

6.1 对应关系

随机游走语言	$\Leftrightarrow$	**知识图谱语言**
有向图顶点	$\Leftrightarrow$	实体（人物、地点、概念……）
有向边	$\Leftrightarrow$	关系（执导、出生于、位于……）
长度 ℓ 的游走	$\Leftrightarrow$	ℓ 跳推理链
非马尔科夫转移	$\Leftrightarrow$	推理时下一跳依赖前缀关系链
最大概率路径（P3）	$\Leftrightarrow$	最可信推理路径（可解释性）

6.2 典型的多跳问题

- **1 跳（马尔科夫可解）**：”《星际穿越》的导演是谁？” $\xrightarrow{\text{执导}^{-1}}$ 诺兰。
- **3 跳（非马尔科夫必要）**：” 诺兰的电影通常在哪个大洲取景？” $\xrightarrow{\text{执导}}$《星际穿越》$\xrightarrow{\text{拍摄地}}$ 英国 $\xrightarrow{\text{位于}}$ 欧洲。此处第三跳” 位于” 的选择**依赖整条前缀链**（不能只看” 英国” 这个顶点）。

与现有 KG 方法的对比

现有 KG 嵌入方法（TransE、RotatE、ComplEx）通常假设马尔科夫性；多跳方法（DRUM、NBFNet、PathRNN）使用启发式路径聚合。**本研究提供了一个有原则的高阶非马尔科夫框架**，明确建模历史依赖，同时用 GNN 克服指数级状态空间。

7 研究问题汇总

RQ1：阶数提升

在非马尔科夫框架下，从 $T^{(1)}$（一步记忆）提升到 $T^{(2)}$（两步记忆）时，概率分布如何变化？GNN 能否从轨迹数据中高效学习这一提升映射，同时满足边缘化一致性约束？

RQ2：路径概率估计

基于 GNN 学习到的路径嵌入，能否高效地计算任意长度路径在 k 阶模型下的概率？如何在不枚举所有路径的情况下给出置信度排序？

RQ3：最大概率路径搜索

对于相距较远的两点 s, t，能否利用 GNN 代理模型（而非精确 DP）通过束搜索或强化学习找到最大概率路径？该路径是否具有可解释性，并能对应知识图谱中的推理链？

8 总结

本文提出并形式化了有向图上非马尔科夫随机游走的研究课题，核心贡献如下：

1. **问题形式化**：引入 k 阶边转移张量 $T^{(k)}$，统一描述马尔科夫与非马尔科夫游走；
2. **三层问题体系**：从阶数提升（局部结构）到路径概率（序列评估）再到最优路径（全局优化），由浅入深构成完整研究课题；
3. **GNN 框架**：基于线图变换，将非马尔科夫历史依赖转化为图上的消息传递，绕开指数级状态空间；
4. **现实意义**：直接对应知识图谱多跳推理，亦适用于交通、推荐、社交网络等领域。

关键词： 非马尔科夫游走 · 高阶马尔科夫链 · 有向图 · 线图 · 边转移张量 · 图神经网络 · 知识图谱 · 多跳推理 · 组合优化